



8장 신경망모형

8.1 서론

- # 신경망 또는 인공신경망(이하 ANN)모형은 동물의 뇌신경계를 모방하여 분류 또는 예측을 위해 만들어진 모형이다.
- # 자연뉴런이 시냅스를 통하여 신호를 전달받는 과정에서, 신호의 강도가 기준치를 초과할 때 뉴런은 활성화가 되고, 신경돌기를 방출하듯이,
- # 인공신경망에서 입력은 시냅스에 해당하며 개별신호의 강도에 따라 가중되고, 활성화함수는 인공신경망의 출력을 계산한다.
- # 많은 데이터에 대해 학습을 거쳐, 원하는 결과가 나오도록(즉 오차가 적어지는 방향으로) 가중치가 조정된다.
- # 안정화된 가중치는 회귀모형에서처럼 입력변수의 영향으로 해석될 수 있다.




(a) 자연신경망



(b) 인공신경망

8.2 신경망 모형

- # 입력층이 은닉층을 거치지 않고 직접 출력층에 연결되는 단층신경망(퍼셉트론)의 네트워크 구조는 다음의 그림과 같다.



- # 위 그림에서 d-차원의 입력벡터 $x = (x_1, x_2, \dots, x_d)'$ 와 스칼라 값 z 는 $z = w'x + w_0$ 또는 $z = w_0 + \sum_{j=1}^d w_j x_j$ 라는 관계를 가진다.
- # z 값에 대해 활성화함수가 적용되어 $y(x)$ 가 계산된다.
- # 이 시스템에서 가중치 $w = (w_1, \dots, w_d)'$ 는 의사결정경계의 방향을 나타내는 모수이며, 편의 w_0 는 의사결정경계의 위치를 결정하는 모수이다.
- # 가중치 w 와 절편 w_0 는 학습을 통해 오차제곱합이 최소가 되는 방향으로 개선된다.
- # 최종의 목표값 $y = y(x)$ 는 z 에 대해 비선형 활성화함수 $\phi(\cdot)$ 를 적용하여 구해진다. $y = \phi(z)$

- ## 많이 사용되는 활성화함수의 예는 다음과 같다.

- # 부호 또는 분계점 함수 : 결과는 이진형(-1 or 1)이다. $y = \begin{cases} -1, & z < 0 \\ 1, & z \geq 0 \end{cases}$

- # 계단 함수 : 결과는 이진형(0 or 1)이다. $y = \begin{cases} 0, & z < 0 \\ 1, & z \geq 0 \end{cases}$

- # 시그모이드 함수 : 결과는 연속형이며 Y축이 0에서 1사이에 존재한다. $y = \frac{1}{1 + \exp(-z)}$

- # Softmax 함수 : 이 함수는 표준화지수(또는 일반화 로지스틱) 함수라고도 하며,

- # 출력값 z 가 여러 개(L개)로 주어지고, 목표치가 다범주인 경우 각 범주에 속할 사후확률을 제공한다. $y_i = \frac{\exp(z_i)}{\sum_{j=1}^L \exp(z_j)}, j = 1, \dots, L$

- # tanh 함수 : 결과는 연속형이며, Y축의 범위가 -1에서 1까지 이다. $y = \frac{\exp(z) - \exp(-z)}{\exp(z) + \exp(-z)}$

- # 가우스 함수 : 결과는 연속형이며, Y축의 범위가 0에서 1사이에 존재한다. $y = \exp(-\frac{z^2}{2})$

```
### 예제 1 : {nnet}nnet()함수를 이용하여 신경망모형을 적합한다.
```

```
## 데이터 불러오기
```

```
library(nnet)
```

```
data(iris)
```

```
## {nnet}nnet()함수를 이용하여 신경망모형을 적합
```

```
# size : 은닉층의 노드 수
```

```
# rang : 초기 랜덤 가중치의 절댓값 범위( 1 -> (-1,1))
```

```
# decay : 디폴트는 0, 가중치가 변하는 속도를 조정한다.
```

```
# maxit : 최대 반복수를 나타내며 디폴트는 100이다.
```

```
nn.iris <- nnet(Species~., data=iris, size=2, rang=0.1, decay=5e-4, maxit=200)
```

```
# 요약, softmax modelling을 사용한다. 따로 지정한 것은 아니며, 연결선의 방향과 가중치를 나타낸다.
```

```
# 다만 초기값을 정하지 않는다면 nnet()함수가 실행될 때마다 결과가 달라질 것이다.
```

```
# 컴퓨터가 발전하면서 나온 계산이 신경망 계산으로 자세한 계산과정을 알기 힘들
```

```
summary(nn.iris)
```

```
## {devtools}plot.nnet()함수를 이용하여 시각화를 진행
```

```
install.packages("devtools")
```

```
library(devtools)
```

```
source_url('https://gist.githubusercontent.com/Peque/41a9e20d6687f2f3108d/raw/85e14f3a292e126f1454864427e3a189c2fe33f3/nnet_plot_update.r')
```

```
# 선의 굵기는 연결선의 가중치에 비례한다.
```

```
plot.nnet(nn.iris)
```

```
## {clusterGeneration, scales, reshape}plot()함수를 이용하여 시각화
```

```
# 3개의 패키지를 불러와 plot()함수를 이용하여 또 다른 방법으로 시각화를 할 수 있다.
```

```
# 이 방법은 url로부터 파일을 가져오지 않아도 되므로 위의 방법보다 편하다.
```

```
install.packages("clusterGeneration")
```

```
install.packages("reshape")
```

```
library(clusterGeneration)
```

```
library(scales)
```

```
library(reshape)
```

```
plot(nn.iris) # 시각화의 결과는 위에 그림과 비슷하게 나온다.
```

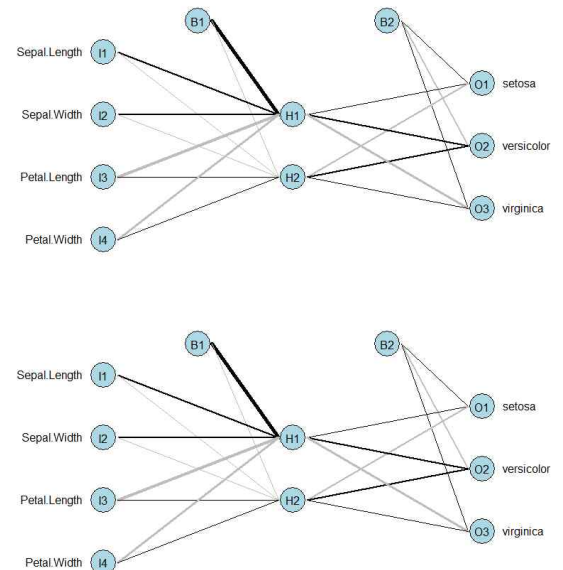
```
## 신경망 모형에 대한 정오분류표는 다음과 같다.
```

```
# 분류된 데이터를 실제 값과 비교해보면, setosa는 50개 모두 잘 분류되었고,
```

```
# versicolor은 50개 중에 49개가, virginica는 50개 중에 49개가 잘 분류되었다.
```

```
table(iris$Species, predict(nn.iris, iris, type = "class"))
```

```
# 결과      setosa versicolor virginica
# setosa      50         0         0
# versicolor   0        49         1
# virginica    0         0        50
```



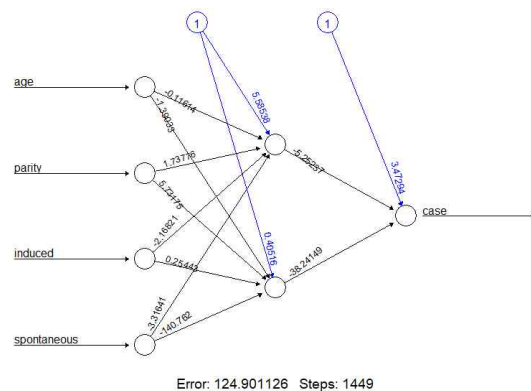
```
### 예제2. {neuralnet}neuralnet() 함수 사용
## 데이터 선언
# 자연유산과 인공유산 후의 불임에 대한 대응 사례-대조 연구 자료로
# 8개의 변수와 248개의 관측값을 가지고 있다. 반응변수 case 변수는 (1: 사례, 0: 대조)를 나타낸다.
data(infert, package="datasets")
str(infert)
```

```
## {neuralnet}neuralnet() 함수 사용하여 다양한 역전파 알고리즘을 통해 신경망 모형을 적합한다.
install.packages("neuralnet")
library(neuralnet)
# hidden : 은닉층의 노드 수
# err.fct : 오차 계산에 사용되는 미분 가능성 함수 : "ssn"(디폴트), "ce"(cross entropy)
# act.fct : 활성화 함수로 디폴트인 "logistic"이 적용된다. "tanh"도 가능하다.
# likelihood=TRUE를 사용하여 AIC, BIC 등이 나올 수 있기 해줌
# 이 값은 여러가지 값들과 비교를 하기 위해 일단 설정을 해놓은 것이다. 하나의 값으로 의미 없음
net.infert <- neuralnet(case~age+parity+induced+spontaneous, data=infert, hidden=2, err.fct="ce",
                        linear.output=FALSE, likelihood=TRUE)

net.infert # 83번째 개체까지 케이스가 1이고 나머지는 0
```

```
## plot()함수를 이용하여 시각화를 한다.
# 은닉층은 1개 은닉층의 노드는 2개(H1, H2)라고 할 수 있다.
# 선의 굵기는 연결선의 가중치에 비례한다.
plot(net.infert)
```

```
## neuralnet()함수에서 사용할 수 있는 메서드 출력
names(net.infert)
```



```
head(net.infert$result.matrix) # 행렬정보결과는 $result.matrix 메서드를 사용
head(net.infert$data) # 전체자료가 저장되어 있다.
head(net.infert$covariate) # 모형적합에 사용된 자료 확인 가능
head(net.infert$response) # 모형적합에 사용된 자료 확인 가능, 적합된 값의 실제 값을 확인할 때 사용
head(net.infert$net.result) # 모형에 대한 적합값을 알려준다.
head(net.infert$startweights) # 가중치의 초기값과 적합값을 확인할 수 있다.
head(net.infert$weights) # 가중치의 초기값과 적합값을 확인할 수 있다.
```

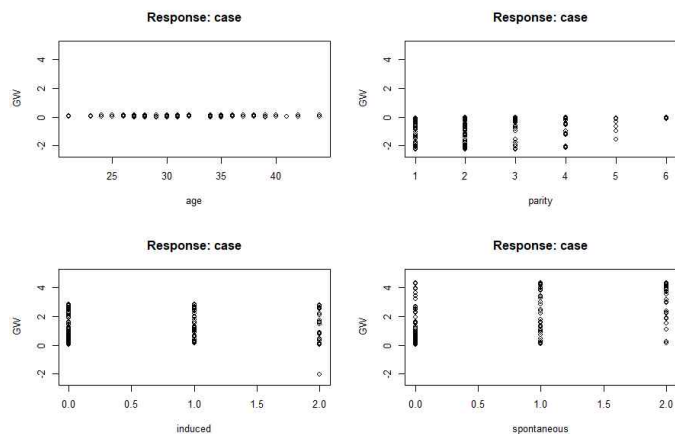
```
## 모형적합에 사용된 자료와 모형에 대한 적합값(불임이 될 확률), 실제 불임의 유무를 바인드하여 출력
# dimnames()함수를 통해서 적합값과 실제 결과에 해당하는 열의 이름을 nn-output, real-case로 부여한다.
# nn-output : 실제로 case로 분류될 확률이 나와 있으며, 불임이 아닐경우는 0, 불임은 1이다.
# real-case : 각 행이 실제 어디값(case)인지 알고싶어서 추가
out <- cbind(net.infert$covariate, net.infert$net.result[[1]], net.infert$response)
dimnames(out) <- list(NULL, c("age","parity","induced", "spontaneous", "nn-output", "real-case"))
head(out) # -----QQQ 5번은 그럼 실제 불임인데 아니라고 판단할 가능성이 크다고 할 수 있는 것 인가?
# 결과
# age parity induced spontaneous nn-output real-case
# [1,] 26 6 1 2 0.1543140 1
# [2,] 42 1 1 0 0.6190054 1
# [3,] 39 6 2 0 0.1448854 1
# [4,] 34 4 2 0 0.1537289 1
# [5,] 35 3 1 1 0.3523065 1
# [6,] 36 4 2 1 0.4901111 1
```

```
## 일반화 가중치
# $generalized.weights가 제시하는 일반화 가중치는 각 공변량들의 효과를 나타내는 것으로
# 호지스틱 회귀모형에서 회귀계수와 유사하게 해석이 된다.(각 공변량들이 log(오즈)에 미치는 기여도)
# 다만, 로지스틱 회귀와는 달리 일반화 가중치는 다른 모든 공변량에 의존하므로
# 각 자료점에서 국소적인 기여도를 나타낸다.
# 예) 동일한 변수가 몇몇 관측값에 대해서는 양의 영향을 가지며, 또 다른 관측값에 대해서는 음의 영향을 가지고
# 예) 모든 자료에 대한 일반화 가중치의 분포는 특정 공변량의 효과가 선형적인지의 여부를 나타낸다.
# 즉, 작은 분산은 선형효과를 나타내며,
# 큰 분산은 관측값 공간상에서 변화가 심하다는 것이므로 비-선형적인 효과가 있음을 알 수 있다.
head(net.infert$generalized.weights[[1]])
```

```
# 결과
# [1] [2] [3] [4]
# [1.] 0.0089548529 -0.133987211 0.167176304 0.25570604
# [2.] 0.1496154535 -2.238624972 2.793140084 4.27227283
# [3.] 0.0004802473 -0.007182208 0.008959544 0.01373697
# [4.] 0.0084484132 -0.126409555 0.157721619 0.24124490
# [5.] 0.1056487373 -1.580771879 1.972334515 3.01680220
# [6.] 0.1351335985 -2.021939854 2.522781316 3.85874311
```

```
## 일반화 가중치에 대한 시각화 진행
# 일반화 가중치의 분포로부터 공변량 age는 모든 값이 0근처의 값을 가지므로 사례-대조 상태에 따른 효과가 없다.
# 공변량(induced, spontaneous)은 일반화 가중치의 분산이 대부분 1보다 크므로 비선형 효과를 가진다고 판단한다.
# 따라서 모형을 단순화 하기 위해 age를 제외한 3개의 공변량으로 신경망모형을 적합할 수 있다.
# 해석 : age를 제외한 3개의 요인에서 분산이 커서 비선형 효과를 가진다고 볼 수 있다.
# age는 영향을 별로 못준다. 따라서 age 제외한 3개로 다시 그려보는게 좋다고 볼 수 있다.
```

```
par(mfrow=c(2,2))
gplot(net.infert, selected.covariate="age", min=-2.5, max=5)
gplot(net.infert, selected.covariate="parity", min=-2.5, max=5)
gplot(net.infert, selected.covariate="induced", min=-2.5, max=5)
gplot(net.infert, selected.covariate="spontaneous", min=-2.5, max=5)
par(mfrow=c(1,1))
```




```
## compute() 함수를 사용하여 새로운 데이터를 대입해 어떤 원인이 중요한지 확인한다.
# compute() 함수는 각 뉴런의 출력값을 계산해준다.
# 데이터 셋 : (나이, 자녀의 수, 유산의 경험(했으면=1), 층의 수)
# 유산의 여부를 알고 싶으면 1,2케이스 비교
# 층의 경우 비교하고 싶으면 1,3번 or 2,4를 비교
# 인공유산의 경우가 있으면 불임이 될 확률이 증가, 즉, 사전 낙태의 수에 따라 예측확률이 증가함을 보인다.
# 층이 달라짐에 따라서 불임의 확률이 달라짐을 확인 할 수 있었다.
# 층이 0에서 1로 바뀔때 인공유산의 경우때보다 불임에 확률에 더 영향을 준다고 이 자료들로 설명 할수있다.
new.output <- compute(net.infert, covariate=matrix(c(22,1,0,0, 22,1,1,0, 22,1,0,1, 22,1,1,1), byrow=TRUE, ncol=4))
new.output$net.result # 불임이 될 확률을 계산
# 결과
# [1.] 0.1063410
# [2.] 0.1676170
# [3.] 0.3572291
# [4.] 0.8540056
```


가중치들에 대한 신뢰구간 confidence.interval()함수 사용
 # 신경망 모형에서 가중치들에 대한 신뢰구간은 confidence.interval()함수를 통해 구할 수 있다.

다층신경망

다층 신경망 또는 다층 퍼셉트론의 네트워크 구조는 다음의 그림과 같다.
 # 다음의 그림은 2개의 은닉층을 가지는 다층신경망의 구조이며, 그 목적은 입력벡터 x 를 출력벡터 $y(x)$ 로 맵핑하는 것이다.



입력층(input layer)은 자료벡터 또는 패턴을 받아들이고,
 # 은닉층(한개 또는 여러개)은 이전층(previous layer)으로부터 출력을 받아 가중을 취한 후 비선형의 활성화함수로 넘긴다.
 # 출력층(output layer)은 최종 은닉층으로부터 결과를 받아 비선형적으로 결과를 넘겨 목표값(target value)을 제공한다.
 # 다층신경망의 가중치는 학습과정에서 오차의 역전파 알고리즘을 통해 갱신된다.
 # 신경망모형은 여러 개의 은닉층을 가질 수 있다.
 # 단층신경망과 다층신경망(2 또는 3개의 인닉층)의 네트워크 구조와 의사결정경계는 다음의 그림과 같다.
 # 여기서 분계점 활성화함수가 사용되었다.



은닉층의 수

은닉층의 수는 의사결정경계를 정하는 데 중요하다. 은닉층의 수를 정할때는 다음의 사항을 고려한다.
 # 다층신경망은 단층신경망에 비해 훈련이 어렵다.
 # 시그모이드 활성화함수를 가지는 2개 층의 네트워크(1개 은닉층)는 임의의 의사결정경계를 모형화할 수 있다.

각 층의 노드수 (또는 units)의 결정은 다음을 고려하여 결정한다.
 # 출력 노드의 수는 출력 변수의 수로 결정한다.
 # 입력의수는 입력 차원의 수로 결정한다.
 # 은닉층 노드의 수는 다음을 고려하여 정한다.
 # 너무 적으면 네트워크의 복잡한 의사결정경계를 만들 수 없다.
 # 너무 많으면 네트워크의 일반화가 어렵다.

```

### 예제3 : {neuralnet}neuralnet() 함수를 이용한 다층신경망모형을 적합
# 데이터 설정
train.input <- as.data.frame(runif(50, min=0, max=100)) # 0과 100사이의 난수 50개를 생성
train.output <- sqrt(train.input) # 생성한 값의 제곱근을 씹어서 자료를 구축
train.data <- cbind(train.input, train.output) # 제곱근을 씹우기 전과 후로 데이터 생성
colnames(train.data) <- c("Input","Output") # 데이터의 열 이름 부여
head(train.data)
# 결과
# Input Output
# 1 81.20390 9.011321
# 2 25.24498 5.024439
# 3 80.79297 8.988491
# 4 54.63995 7.391884
# 5 28.15972 5.306573
# 6 65.91800 8.118990

```

```


## 1개의 은닉층과 10개의 은닉노드를 가지는 신경망 모형을 적합한다.
# threshold= 옵션을 이용하여 오차함수의 현미분에 대한 값으로 정지규칙으로 사용된다.
library(neuralnet)
net.sqrt <- neuralnet(Output~Input,train.data, hidden=10, threshold=0.01)
net.sqrt

```

```

## plot()함수를 이용하여 적합된 다중신경망 모형을 시각화 한다.
plot(net.sqrt)

```



```

## 검증
# 몇 개의 검증용 자료에 대해 구축된 신경망 모형을 적용한다.
# 1에서 10까지 값을 제공할 수로 검증용 자료를 만든후, compute()함수를 통해 신경망모형을 적용
# 각 노드가 각 숫자들과 비슷한 걸로 보아 잘 적합 되었다고 볼 수 있다.
test.data <- as.data.frame((1:10)^2)
test.out <- compute(net.sqrt, test.data)
ls(test.out)
print(test.out$net.result) # 결과가 각 번째의 숫자와 비슷한 것으로 보아 잘 적합되었음을 알 수있다.
# 결과 : [,1]
# [1,] 1.004772
# [2,] 1.997578
# [3,] 2.999734
# [4,] 4.001517
# [5,] 4.998745
# [6,] 6.003209
# [7,] 6.996518
# [8,] 7.998204
# [9,] 9.006229
# [10,] 9.967341

```

```


### 층이 여러개인 다중신경망 모형을 적합
# hidden= 옵션에 c(10,8)를 입력하여 2개의 은닉층을 가지고, 각각의 은닉노드의 수는 10개 8개로 한다.
net2.sqrt <- neuralnet(Output~Input,train.data, hidden=c(10,8), threshold=0.01)

```

```

## 결과를 시각화 하였다.
plot(net2.sqrt)

```



은닉층을 늘리면, 1부터 10까지의 수들이 조금더 정확하게 예측을 하는 것을 확인하였다.

```
test2.out <- compute(net2.sqr, test.data)
```

```
print(test2.out$net.result)
```

```
# 결과 : [,1]
# [1,] 0.9966773
# [2,] 1.9996790
# [3,] 2.9984045
# [4,] 4.0030684
# [5,] 4.9984873
# [6,] 6.0016115
# [7,] 7.0001056
# [8,] 7.9985686
# [9,] 9.0025563
# [10,] 9.9760321
```

신경망모형의 장단점

장점

변수의 수가 많거나 입, 출력 변수 간의 복잡한 비선형 관계가 존재할 때 유용

잡음에 대해서도 민감하게 반응하지 않는다

단점

결과에 대한 해석이 쉽지 않으며

은닉층의 수와 은닉 노드 수의 결정이 어렵고, 초기값에 따라 전역 해가 아닌 지역 해로 수렴할 수 있다.

모형이 복잡하면 훈련과정에 시간이 많이 소요될 수 있다.

딥러닝의 소개

인공신경망에 대한 연구는 최초로 인간두뇌에 관한 노리적 모델을 제시한 McCulloch와 Pitts의 논문을 시작으로

Rosenblatt의 퍼셉트론(단층신경망)이 큰 이슈를 몰고 왔으나

단층 신경망으로 XOR 연산이 불가능함이 증명되면서 많은 사람들이 관심을 돌렸다.

이후 다층신경망의 역전파를 이용해 XOR 문제를 해결할 수 있음이 증명되며 다시 사람들의 관심을 사게 되었다.

하지만 그 이후에 한번 더 관심이 없어지게 되었는데 이유는 두가지로 나뉜다.

첫째, 신경망의 깊이가 깊어질수록 학습이 잘 되지 않으며

둘째, 파라미터 최적화에 대한 이론적인 근거가 없다는 것이었다.

Hinton 은 가중치의 초기값을 계대로 설정하면 깊은 신경망도 학습할 수 있다는 것을 보였다.

이어서 벤지오 팀은 좀 더 간단한 자기 부호화기를 사용한 사전-훈련방법을 제안하였다.

두 논문으로부터 딥러닝 또는 심층신경망이 탄생하게 되었다.

딥러닝은 빠른 속도로 발전하여 Hinton교수 제자 Alex가 AlexNet이라는 딥러닝 알고리즘을 통해 전년도 보다 10% 오류를 줄인 보습을 보여

많은 연구자들이 딥러닝으로 방향을 전환하는 계기가 되었다.

최근에는 빅데이터와 빠른 컴퓨팅 기술과 결합하여 많은 분야에 적용되고 있다.

IBM 왓슨 - 인간과 퀴즈대결

구글 Andrew Ng - 이미지와 비디오의 패턴 감지

딥마인드 - 인간과 Atrigeim에서 이기도록

페이스북 - DeepFace DNN 사람 인식

아마존 - 아마존 머신러닝

마이크로소프트 - DMTK 분산 기계학습 툴팁

구글 알파고

구글 텐서플로우

마이크로소프트 심층학습 툴킷